

PRUEBA TÉCNICA – ANALISTA SENIOR DE GOBIERNO DE DATOS

HDI Seguros Colombia | Gerencia de Datos y Analítica

Sección B: Gobierno de Datos, Normativas y Trazabilidad

B1. Ficha del KPI: “% Siniestros pagados en 1 día”

Definiciones previas

Término	Definición
Siniestro	Materialización del riesgo cubierto por una póliza que genera un reclamo del asegurado a la compañía.
FNOL (First Notice of Loss)	Primer aviso de siniestro. Fecha en que el asegurado o sus beneficiarios reportan el evento a HDI Seguros. Es el punto de partida del SLA.
SLA 1 día	Acuerdo de Nivel de Servicio que establece que el pago del siniestro debe realizarse dentro de 1 día calendario desde la recepción del FNOL.

Ficha técnica del KPI

Elemento	Descripción
Objetivo	Medir la eficiencia operativa en el pago de siniestros dentro del SLA establecido
Definición	Porcentaje de siniestros pagados cuya diferencia entre fecha de FNOL y fecha de pago es 1 día
Fórmula	$\left(\frac{\text{Siniestros pagados en 1 día}}{\text{Total de siniestros pagados en el período}} \right) \times 100$
Fuente autorizada	Amazon Redshift (plataforma analítica objetivo)
Granularidad	Mensual, segmentable por canal y producto
Owner	Dirección de Siniestros

Elemento	Descripción
Steward	Analista de Gobierno de Datos — Dominio Siniestros
Supuesto crítico #1	La calidad del registro de <code>fecha_fnol</code> y <code>fecha_pago</code> es fundamental: fechas nulas o incorrectas distorsionan el KPI. Si un siniestro tiene <code>fecha_pago</code> nula, no puede incluirse en el cálculo, subestimando el denominador.
Supuesto crítico #2	La definición de “pagado” asume <code>estado_siniestro = 'Pagado'</code> con <code>fecha_pago</code> no nula. Siniestros con pagos parciales progresivos sin cierre formal podrían no reflejarse adecuadamente si el estado no se actualiza hasta el pago total.

B2. Protección de datos y clasificación

Campos con datos personales o sensibles

Campo	Clasificación	Fundamento
<code>id_cliente</code>	Dato personal (indirecto)	Identificador único que permite asociar información a una persona natural
<code>tipo_doc</code>	Dato personal	Describe el tipo de documento de identidad (CC, CE, NIT, etc.)
<code>nro_doc_hash</code>	Dato personal seudonimizado	Aunque es hash SHA-256, sigue siendo un identificador susceptible de re-identificación por fuerza bruta; debe tratarse como PII seudonimizada
<code>ciudad</code>	Dato personal (indirecto)	Ubicación geográfica que en combinación con otros datos puede identificar a una persona

Campo	Clasificación	Fundamento
segmento	Dato sensible (comercial)	Clasificación comercial interna que refleja perfilamiento del cliente
banco	Dato personal financiero	Entidad bancaria del asegurado; dato sensible según normativa financiera

Normativa colombiana aplicable

Norma	Alcance
Ley 1581 de 2012	Régimen general de protección de datos personales en Colombia
Decreto 1377 de 2013	Decreto reglamentario de la Ley 1581
Ley 1266 de 2008	Habeas Data financiero — protección de datos crediticios y financieros
Circular Externa 002 de 2022 SFC	Instrucciones de la Superintendencia Financiera para reporte y custodia de datos
Decreto 2555 de 2010 (modificado)	Normativa del sector asegurador colombiano

3 recomendaciones concretas de almacenamiento y acceso seguro

1. **Encriptación en reposo con AWS KMS:** Todos los campos clasificados como personales o sensibles deben almacenarse con encriptación AES-256 en S3 y Redshift, con rotación automática de llaves (CMK) y separación de responsabilidades entre administrador de llaves y administrador de datos.
2. **Tokenización progresiva por capa:** En la capa S3 Raw se almacena el `nro_doc_hash` original (seudonimizado). En las capas Refined y Redshift, sustituir por un identificador surrogate sin relación directa con el dato fuente, asegurando que la re-identificación requiera acceso explícito a la capa Raw.
3. **Control de acceso granular con AWS Lake Formation + IAM:** Implementar políticas RBAC que restrinjan el acceso a columnas sensibles (`banco`, `segmento`, `nro_doc_hash`) solo al equipo de Gobierno de Datos y áreas autorizadas (Regulatorio, Cumplimiento), con registro de acceso auditado vía CloudTrail y alertas en CloudWatch para accesos no autorizados.

B3. Linaje del dato y controles en AWS

Diagrama de linaje del dato (KPI → Dashboard)

```
flowchart LR
    subgraph Fuente
        A["Sistemas Core<br/>(OLTP)"]
    end

    subgraph Ingesta
        B["S3 Raw<br/>(DMS / Firehose)"]
    end

    subgraph Transformación
        C["AWS Glue ETL<br/>(Limpieza y casting)"]
        D["S3 Refined<br/>(Parquet - Curado)"]
    end

    subgraph Almacenamiento
        E["Amazon Redshift<br/>(Fuente Autorizada)"]
    end

    subgraph Calidad
        F["AWS Deequ / DataBrew<br/>(Reglas de Calidad)"]
    end

    subgraph KPI
        G["dbt / Vistas SQL<br/>(Cálculo del KPI)"]
    end

    subgraph Consumo
        H["Amazon QuickSight<br/>(Dashboard)"]
    end

    subgraph Auditoria
        I["AWS CloudTrail<br/>+ Config"]
    end

    A -->|"CDC Diario<br/>(DMS)"| B
    B -->|"QC1: Validación<br/>de esquema y tipos"| C
    C -->|"QC2: Perfil de calidad<br/>(DataBrew)"| D
    D -->|"COPY<br/>Redshift Spectrum"| E
    E -->|"QC3: Reglas<br/>Deequ (4 reglas A3)"| F
    F -->|"Datos certificados"| G
    G -->|"KPI calculado"| H
```

```

I -.->|"Audita acceso"| B
I -.->|"Audita acceso"| E
I -.->|"Audita queries"| G
I -.->|"Audita consumo"| H

```




Figure 1: Diagrama de linaje del dato

Generación de evidencia de controles

Paso	Control	Evidencia generada	Dónde se almacena
QC1 (S3 Raw → Glue ETL)	Validación de esquema y tipos de datos	Logs de Glue con registros rechazados por schema mismatch	S3 logs + CloudWatch
QC2 (Glue ETL → S3 Refined)	Perfil de calidad con DataBrew (NULLs, outliers, duplicados)	Reporte HTML de perfil de datos y reglas de calidad evaluadas	DataBrew jobs output + S3
QC3 (Redshift → Deequ)	Ejecución de reglas de calidad (completitud, unicidad, validez temporal, conciliación)	Tabla dq_results con timestamp, regla, pass/fail, registros afectados	Redshift (esquema governance)
Auditoría continua	CloudTrail + Config	Logs de todas las API calls (acceso a S3, queries Redshift, cambios IAM)	S3 (bucket de auditoría) con retención de 7 años

4 controles mínimos de gobernanza en AWS para un Data Lake

1. **AWS Lake Formation + IAM Policies:** Control de acceso granular a nivel de base de datos, tabla, columna y fila. Permite definir permisos por rol (Data Scientist, Steward, Auditor) sin gestionar políticas IAM individuales. *Evidencia:* políticas de acceso documentadas y registros de acceso en CloudTrail.

2. **AWS KMS con rotación automática:** Encriptación en reposo para S3, Redshift y Glue con CMKs separadas por ambiente (dev, staging, prod). Política de rotación automática cada 90 días. *Evidencia: CloudTrail logs de uso de llaves y política de rotación.*
3. **AWS Glue Catalog + Amazon DataZone:** Catálogo centralizado con metadatos técnicos y de negocio, linaje automatizado, clasificación de datos (PII, sensible, público) y certificación de activos. *Evidencia: activos catalogados con propietario, steward, clasificación y fecha de certificación.*
4. **AWS CloudTrail + AWS Config + EventBridge:** Registro continuo de todas las operaciones del Data Lake con alertas automáticas para: accesos no autorizados, modificaciones en políticas IAM, cambios en configuraciones de encriptación. *Evidencia: trail de auditoría inmutable en S3 con alerts en SNS.*

Resumen de priorización de reglas de calidad (A3)

Prioridad	Regla	Impacto en KPI	Acción inmediata
1	Compleitud	Sin fechas no hay KPI	Solicitar a fuente completar NULLs o implementar default rules
2	Unicidad	Duplicados inflan el indicador	Depurar duplicados y agregar PK/FK constraints
3	Validez temporal	Fechas incorrectas alteran el SLA	Validar en fuente y rechazar registros con inversión de fechas
4	Conciliación	Afecta confianza financiera	Investigar diferencias y corregir en fuente transaccional
5	Integridad referencial	Limita segmentación	Corregir asignación de pólizas huérfanas